

TP 3 - BERT

Chloe Makoundou

Fevrier 2026

1 Introduction

Le traitement du langage naturel (NLP - *Natural Language Processing*) a connu une révolution majeure au cours des dernières décennie. Ce rapport présente le travail réalisé dans le cadre du TP3 BERT, portant sur le résumé automatique de texte littéraire à l'aide du modèle **BARThez.ipynb**. Ce TP vise à résumer le chapitre 27 de *Léon l'Africain* d'Amin Maalouf, un texte complexe dont la longueur dépasse la fenêtre contextuelle des modèles standards. Nous utilisons le modèle **BARThez** via deux stratégies : un traitement par segments classiques et une approche **Map-Reduce** optimisée pour garantir la cohérence globale du résumé final.

1.1 Configuration et Lancement

Le projet est conçu pour être reproductible avec Python 3.10. Pour obtenir les mêmes résultats :

1. **Environnement virtuel :**

- *macOS / Linux* : `python3.10 -m venv env310 && source env310/bin/activate`
- *Windows* : `python -m venv env310 && env310\Scripts\activate`

2. **Installation :** `pip install -r requirements.txt`

3. **Exécution :** Lancer le script `test_barthez.py`. Le modèle sera téléchargé automatiquement et les résultats (résumés et graphiques) seront générés dans les dossiers respectifs `/resumes` et `/visualisations`.

2 Contexte Théorique

2.1 Évolution des architectures : des RNN au Transformer

Avant l'arrivée des Transformers, on utilisait surtout les réseaux de neurones récurrents (RNN) et les LSTM *Long Short-Term Memory* pour traiter du texte. Ces modèles analysent les données les unes après les autres. Pour comprendre

un mot, le modèle utilise un "état caché" (h_t) qui garde en mémoire ce qu'il a appris des mots précédents (h_{t-1}).

Cependant, cette approche présente deux défauts majeurs :

1. **Le problème du gradient** : Lors du calcul de la rétropropagation temporelle (BPTT), la multiplication répétée des matrices de poids peut entraîner une disparition ou une explosion du gradient, rendant difficile l'apprentissage des dépendances à long terme.
2. **Absence de parallélisation** : Le calcul à l'instant t ne peut débuter qu'après la fin de l'étape $t - 1$, limitant l'utilisation de la puissance de calcul des GPU modernes.

2.2 Le mécanisme d'Auto-Attention

Le modèle Transformer, remplace la récurrence par le mécanisme de *Scaled Dot-Product Attention*. Ce mécanisme permet au modèle de projeter chaque mot dans trois espaces vectoriels distincts : les Requêtes (Q), les Clés (K) et les Valeurs (V).

D'après les supports de cours, l'attention est calculée selon la formule :

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (1)$$

Où d_k est la dimension des clés. Cette opération permet de calculer un score de similarité entre chaque paire de mots, permettant au modèle de focaliser ses "ressources attentionnelles" sur les parties les plus pertinentes du contexte, quelle que soit leur position.

2.3 Le modèle BARThez

BARThez, une adaptation francophone du modèle BART (*Bidirectional and Auto-Regressive Transformers*). BART est une architecture de type encodeur-décodeur qui combine :

- Un encodeur bidirectionnel (similaire à BERT) pour bien comprendre le contexte global.
- Un décodeur autorégressif (similaire à GPT) pour générer le texte mot après mot.

BARThez a été pré-entraîné sur un très large corpus de français. **OrangeSum**, un jeu de données composé d'articles de presse (type Orange Actu).

3 Méthodologie

Pour ce TP, nous avons mis en place une chaîne de traitement allant de l'extraction du texte brut à la génération d'un résumé optimisé.

3.1 Stratégies de traitement de texte long

La mémoire limitée des Transformers (1024 tokens) impose un découpage du texte. Nous avons comparé deux méthodes :

- **Approche Standard** : Segmentation par phrases (`nltk`) en blocs de 1000 caractères, résumés individuellement puis concaténés.
- **Approche Map-Reduce (Boostée)** : Le texte est divisé en 8 morceaux résumés en parallèle (*Map*). Ces sous-résumés sont ensuite fusionnés et résumés une seconde fois (*Reduce*). Cette méthode améliore la cohérence globale et limite les redondances.

3.2 Configuration et Paramètres du Modèle

Le succès de la génération dépend de la configuration fine de la méthode `model.generate()`. Voici l'explication des paramètres retenus dans notre script `test_barthez.py` :

- **num_beams = 4** : Nous utilisons une *Beam Search* (recherche par faisceaux). Au lieu de choisir le mot le plus probable à chaque étape (Greedy Search), le modèle explore les 4 séquences les plus prometteuses en parallèle. Cela améliore considérablement la cohérence grammaticale.
- **max_length = 150** : Ce paramètre définit la limite supérieure de tokens pour le résumé. Il force le modèle à être synthétique tout en laissant assez d'espace pour couvrir les points clés du chapitre.
- **no_repeat_ngram_size = 3** : Ce paramètre est crucial pour éviter les répétitions. Il interdit au modèle de générer une suite de 3 mots déjà apparue dans le résumé. Cela limite l'effet de "bouclage" fréquent chez les Transformers.
- **length_penalty = 2.0** : Une pénalité de longueur supérieure à 1.0 encourage le modèle à générer des séquences plus longues. Pour un texte littéraire comme celui d'Amin Maalouf, cela permet d'éviter des résumés trop lapidaires qui omettraient les nuances du récit.
- **early_stopping = True** : Indique au modèle d'arrêter la génération dès que tous les faisceaux (*beams*) ont atteint le token de fin de phrase (`</s>`), optimisant ainsi le temps de calcul.

Au niveau du tokenizer, nous utilisons **truncation = True** avec une fenêtre de **1024 tokens**. C'est la limite physique du modèle BARThez au-delà de laquelle l'attention ne peut plus être calculée de manière fiable.

4 Résultats et Analyse

Cette section présente les performances des deux approches testées (Standard vs Boostée) et analyse le comportement du modèle face à un petit texte (généré grâce à une IA concernant les licornes).

nous mettrons en oeuvre deux types de métriques d'évaluation :

1. **ROUGE** (*Recall-Oriented Understudy for Gisting Evaluation*), qui mesure le chevauchement de n-grammes entre le résumé généré et un résumé de référence.
2. **BERTScore**, qui utilise des plongements contextuels pour évaluer la similarité sémantique, offrant une mesure plus fine que le simple comptage de mots.

4.1 Comparaison des scores ROUGE et BERTScore

Les résultats obtenus montrent des différences intéressantes entre les deux méthodes :

Données / Méthode	ROUGE-1	ROUGE-L	BERTScore (F1)
<i>Texte de Test</i>	0.2353	0.1765	0.7561
Chap. 27 - Standard	0.3086	0.1543	0.6347
Chap. 27 - Boostée	0.2222	0.1666	0.6191

Table 1: Synthèse des résultats : ROUGE-1, ROUGE-L et BERTScore

L'analyse du tableau révèle un "fossé" de performance de près de 14 points de BERTScore. Plusieurs facteurs expliquent cette différence :

- **Densité d'information** : Le texte de test ne contient qu'une seule idée principale, alors que le Chapitre 27 entrelace des descriptions historiques, des dialogues et des intrigues politiques.
- **Vocabulaire** : BARThez a été entraîné sur du français moderne.
- **Longueur du contexte** : Comme expliqué en cours, l'attention doit se répartir sur tous les tokens. Sur un texte court (test), l'attention est très concentrée et précise. Sur un texte long (chapitre), elle se dilue, ce qui favorise les hallucinations.
- **ROUGE** : On remarque que la méthode "Boostée" améliore légèrement le **ROUGE-L** (la structure des phrases), mais fait baisser le **ROUGE-1**. Cela s'explique par le fait que le résumé final est plus court et plus synthétique, donc il contient moins de mots-clés exacts de la référence.
- **BERTScore** : Le score sémantique baisse légèrement avec la méthode Boostée (0.63 $\rightarrow$ 0.61). Comme expliqué dans le cours sur les fonctions de perte, le modèle cherche à maximiser la probabilité de la séquence suivante, ce qui peut parfois l'écarter du sens réel s'il est trop "créatif".

4.2 Analyse de la Tokenisation

Conformément aux consignes, nous avons testé le découpage du texte par le tokenizer de **BARThez**. Voici le résultat pour une phrase extraite du chapitre:

"Elle avait prononcé ces mots en arabe, mais avec cet accent circassien..."

Résultat dans le terminal :

```
Texte : "Elle avait prononcé ces mots en arabe,
mais avec cet accent circassienque tous les Cairotes
reconnaissent sans peine, puisqu'il est celui des
sultans et des officiers mamelouks. Avant que j'aie pu répondre,
le marchand était revenu, avec l'offre d'un prix"
Tokens : [' Elle', ' avait', ' prononcé', ' ces', ' mots', ' en', ' arabe',
',', ' mais', ' avec', ' cet', ' accent', ' cir', ' c', ' assi',
'en', ' que', ' tous', ' les', ' Cai', ' ro', ' tes', ' reconnaissent',
'sans', ' peine', ', ', ' puisqu', ' ', ' il', ' est', ' celui',
'des', ' s', ' ult', ' ans', ' et', ' des', ' officiers', ' mam', ' el',
'ou', ' ks', ' .', ...]
```

On observe ici le mécanisme de **Subword Tokenization**. Les mots qui ne sont pas dans le dictionnaire de base ou qui sont morphologiquement riches sont décomposés :

- ' cir', ' c', ' assi', ' en', ' que' : Le mot "circassienque" est brisé en 5 unités.
- ' Cai', ' ro', ' tes' : "Cairotes" est découpé, ce qui permet au modèle de comprendre la racine "Caire" même s'il n'a jamais vu le pluriel exact.
- ' mam', ' el', ' ou', ' ks' : "mamelouks" est également segmenté.

4.3 Analyse de l'Attention et Visualisation

La matrice d'attention est une représentation visuelle des poids calculés par le mécanisme de *Self-Attention*. Elle permet de comprendre sur quels tokens l'encodeur se focalise pour construire la représentation vectorielle d'un mot donné. Dans le cadre de ce TP, nous avons extrait la matrice de la dernière couche de l'encodeur de **BARThez**. En observant la matrice générée




Figure 1: Matrice d’auto-attention du modèle BARThez. Les intensités supérieures à 0,5 révèlent les connexions sémantiques prioritaires.

on remarque plusieurs phénomènes caractéristiques :


- **La diagonale forte** : Le modèle accorde naturellement une attention élevée au token lui-même pour préserver son identité sémantique.
- **Dépendances syntaxiques ($> 0,5$)** : Les scores d’attention dépassant le seuil de 0,5 (zones les plus sombres) indiquent des relations cruciales. Par exemple, le modèle lie fortement le sujet "Nour" à son verbe ou à ses compléments directs, permettant de résoudre les ambiguïtés de contexte.
- **Structure globale** : L’attention ne se limite pas aux mots adjacents, prouvant que le Transformer capture des dépendances à longue distance que les modèles RNN auraient ignorées.

4.4 Analyse qualitative et Hallucinations


Le point le plus marquant de ce TP est le phénomène d’**hallucination** on peut le voir dans le dossier "resume". Bien que BARThez soit très fluide, il a tendance à inventer des informations basées sur ses données d’entraînement (*OrangeSum*) au lieu de rester fidèle au texte source :

1. **Biais journalistique** : Le modèle insère des termes comme "CHRONOLOGIE", "Le Figaro" ou "rapporte l’AFP". Le modèle traite un roman comme un article de presse.

2. **Incohérences historiques** : Dans le résumé boosté, le modèle a décrit le voyageur Ibn-Batouta comme "roi de l'Arabie Saoudite". C'est une erreur majeure, l'Arabie Saoudite n'existant pas à l'époque du récit.
3. **Répétitions** : Avant l'optimisation de la température et du *no_repeat_ngram_size*, le modèle restait bloqué sur des phrases concernant "Le prince Aladin", montrant une difficulté à sortir de ses prédictions les plus probables (*Mode Collapse*).




(a) Métriques ROUGE (Bâtons)




(b) BERTScore (Bâtons)

Figure 2: Comparaison des scores par histogrammes entre le chapitre 27 et le texte de test.



(a) Courbes ROUGE



(b) Courbes BERTScore

Figure 3: Évolution des scores ROUGE et BERTScore.




Figure 4: Évolution des scores ROUGE et BERTScore entre chap27 standard et boosté.

4.5 Discussion sur les limites

L’analyse montre que pour du texte littéraire, le **BERTScore** est plus représentatif que le **ROUGE**, car il accepte les synonymes. Cependant, même avec une architecture avancée comme le Transformer, la qualité du résumé dépend énormément des données de pré-entraînement. Un modèle entraîné sur des dépêches AFP aura toujours du mal à capturer la subtilité d’un roman historique sans un *fine-tuning* spécifique.

5 Conclusion

Ce TP a permis d’appliquer le modèle **BARThez** au résumé littéraire, révélant plusieurs enseignements :

- **Technique** : L’efficacité du résumé dépend crucialement de la stratégie de découpage choisie.
- **Métriques** : La complémentarité entre **ROUGE** et **BERTScore** est nécessaire pour évaluer à la fois la syntaxe et la sémantique.
- **Limites** : Les **hallucinations** et le biais journalistique rappellent que ces modèles sont des prédicteurs statistiques sans compréhension logique réelle.

5.1 Perspectives

Pour améliorer ces résultats, un **fine-tuning** sur corpus littéraire et l’intégration du **RLHF** (*Reinforcement Learning from Human Feedback*) permettraient d’aligner la génération sur la vérité factuelle. Bien que les modèles à attention aient révolutionné le NLP, le domaine littéraire exige encore une supervision humaine et des outils d’évaluation plus fins.